



تمرین شماره ۲

سوالات تحلیلی

۱. (۱۵ نمره)

شبکه‌ی پرسپترون چندلایه با مشخصات زیر را در نظر بگیرید:

- ورودی: $x \in \mathbb{R}^n$
 - لایه‌ی مخفی: $h = \sigma_h(W_1x + b_1)$ که در آن تابع فعال‌ساز ReLU است.
 - خروجی شبکه: $\hat{y} = \sigma_o(W_2h + b_2)$ که در آن تابع فعال‌ساز Sigmoid است.
- برای این شبکه، دو تابع هزینه‌ی متفاوت زیر را در نظر بگیرید:

MSE (آ)

$$L_{MSE} = \frac{1}{2}(\hat{y} - y)^2$$

Cross-Entropy Binary (ب)

$$L_{BCE} = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

با استفاده از قاعده‌ی زنجیره‌ای، مشتقات جزئی زیر را برای هر دو تابع هزینه استخراج کنید:

$$\frac{\partial L}{\partial W_2}, \quad \frac{\partial L}{\partial b_2}, \quad \frac{\partial L}{\partial W_1}, \quad \frac{\partial L}{\partial b_1}$$

۲. (۱۰ نمره)

یک شبکه‌ی عصبی عمیق با L لایه را در نظر بگیرید که در تمامی لایه‌های آن از تابع فعال‌ساز سیگموئید $\sigma(z) = \frac{1}{1+e^{-z}}$ استفاده شده است.

(آ) نشان دهید که بیشینه‌ی مقدار مشتق این تابع فعال‌ساز برابر با ۰.۲۵ است. این مقدار بیشینه در چه نقطه‌ای رخ می‌دهد؟

(ب) با استفاده از قاعده‌ی زنجیره‌ای، نشان دهید که سیگنال خطا در لایه‌ی k (یعنی $\delta^{(k)}$) چگونه با ضرب‌های متوالی مشتقات لایه‌های بعدی به دست می‌آید. سپس با فرض این‌که اندازه‌ی وزن‌ها حدوداً ۱ باشد، ثابت کنید که برای نرم‌گرادیان در لایه‌های ابتدایی رابطه زیر برقرار است:

$$\|\delta^{(1)}\| \leq (0.25)^{L-1} \|\delta^{(L)}\|$$

با استناد به این نابرابری، توضیح دهید که چرا با افزایش تعداد لایه‌ها (L)، سرعت یادگیری در لایه‌های نزدیک به ورودی به شدت کاهش می‌یابد و اصطلاحاً گرادیان محو می‌شود.

۳. (۱۰ نمره امتیازی)

قضیه تقریب‌گر عمومی (Universal Approximation Theorem) بیان می‌کند که یک شبکه‌ی پرسپترون چندلایه با تنها یک لایه‌ی مخفی به شرط آن‌که تعداد نورون‌های آن کافی باشد می‌تواند هر تابع پیوسته روی یک بازه‌ی فشرده را با دقت دلخواه تقریب بزند.

توجه کنید که این قضیه تنها وجود چنین تقریب‌سازی‌ای را تضمین می‌کند و چیزی درباره‌ی کارایی، تعداد نورون‌های لازم یا نحوه‌ی آموزش ارائه نمی‌دهد.

(آ) با وجود این قضیه، چرا در عمل به‌جای شبکه‌های بسیار Wide (پهن با یک لایه‌ی مخفی بزرگ)، از شبکه‌های Deep (دارای چندین لایه‌ی مخفی) استفاده می‌کنیم؟ توضیح دهید که چه محدودیت‌هایی از نظر تعداد پارامترها، قابلیت بیان، و سهولت یادگیری مطرح می‌شوند.

(ب) یک مثال از تابعی ارائه دهید که نمایش آن با تنها یک لایه‌ی مخفی نیاز به تعداد نامایی نورون دارد، اما اگر عمق مدل افزایش یابد، با تعداد بسیار کم‌تری نورون قابل بیان است. (برای نمونه می‌توانید به تابع‌هایی با ساختار سلسله‌مراتبی یا ترکیب‌های تکرارشونده‌ی ساده اشاره کنید.)

۴. (۱۵ نمره)

در مسائل بهینه‌سازی شبکه‌های عصبی، هدف دستیابی به بهینه‌ی سراسری با استفاده از تحلیل رفتاری بردار گرادیان g_t است، این سوال به بررسی سه الگوریتم بهینه‌سازی در همین راستا می‌پردازد.

(آ) Momentum

به‌روزرسانی پارامترها در الگوریتم مومنتوم به صورت زیر تعریف می‌شود:

$$v_t = \beta_1 v_{t-1} + (1 - \beta_1) g_t, \quad \theta_{t+1} = \theta_t - \alpha v_t$$

توضیح دهید چگونه اعمال این روش منجر به میرا شدن نوسانات بردار گرادیان در ابعاد با تغییرات سریع شده و در عین حال مؤلفه‌های ثابت بردار گرادیان در مسیر اصلی را تقویت می‌کند؟ چرا اعمال این الگوریتم بر یک سیگنال (گرادیان)، معادل میانگین‌گیری با وزن‌های نامایی از تاریخچه آن است؟

(ب) RMSProp

در مناطقی که سطح تابع هزینه ناهموار است، دامنه (Amplitude) بردار گرادیان در راستاهای مختلف بسیار متفاوت است. الگوریتم RMSProp برای مقابله با این پدیده از میانگین متحرک توان دوم گرادیان‌ها (s_t) استفاده می‌کند:

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2) g_t^2, \quad \theta_{t+1} = \theta_t - \alpha \frac{g_t}{\sqrt{s_t} + \epsilon}$$

تحلیل کنید که چگونه تقسیم مؤلفه‌های بردار گرادیان بر جذر میانگین مربعات ($\sqrt{s_t}$)، منجر به نرمال‌سازی گام‌های حرکت در جهت‌های مختلف می‌شود؟ این عمل چگونه از ناپایداری در راستاهای با گرادیان بزرگ جلوگیری کرده و سرعت همگرایی در راستاهای با گرادیان کوچک را افزایش می‌دهد؟

(ج) Adam

الگوریتم Adam با ترکیب مفاهیم مطرح شده در Momentum و RMSProp از دو بردار گشتاور اول (m_t) و دوم (v_t) استفاده می‌کند. با توجه به روابطی که در بخش‌های قبل بررسی کردید، توضیح دهید که چگونه ترکیب این دو مفهوم، Adam را به یک بهینه‌ساز تطبیقی تبدیل کرده است که به طور خودکار نرخ یادگیری را برای هر پارامتر تنظیم می‌کند؟

سوالات شبیه سازی

۵. پیش‌بینی قیمت مسکن (۳۰ نمره)

در این سؤال قصد داریم با استفاده از مجموعه داده واقعی Ames Housing مربوط به شهر Ames در ایالت Iowa، یک مدل مبتنی بر شبکه عصبی چندلایه (MLP) برای پیش‌بینی قیمت فروش خانه‌ها طراحی و پیاده‌سازی کنیم. این مجموعه داده شامل اطلاعات مختلفی درباره ویژگی‌های فیزیکی و محیطی خانه‌ها است. هدف این مسئله پیش‌بینی مقدار SalePrice می‌باشد که یک مسئله از نوع Regression است.

نمونه‌ای از ویژگی‌های موجود در داده:

- Overall Qual: کیفیت کلی ساخت ساختمان
- Year Built: سال ساخت
- Gr Liv Area: مساحت فضای زندگی
- Total Bsmt SF: مساحت زیرزمین
- Garage Area: مساحت گاراژ
- Neighborhood: محله
- SalePrice: قیمت فروش (متغیر هدف)

(الف) بررسی اولیه داده

- مجموعه داده را بارگذاری کرده و ده سطر اول آن را نمایش دهید.
- تعداد نمونه‌ها و ویژگی‌ها را گزارش کنید.
- بررسی کنید کدام ستون‌ها دارای Missing Value هستند.
- نمودار هیستوگرام متغیر هدف (SalePrice) را رسم کرده و میانگین آن را گزارش کنید.

(ب) پیش‌پردازش داده

- مقادیر گم شده در ویژگی‌های عددی را با میانگین و در ویژگی‌های کیفی با مد جایگزین کنید.
- ویژگی‌های کیفی را با استفاده از One-Hot Encoding به مقادیر عددی تبدیل کنید.
- تعداد ویژگی‌ها را پس از انجام Encoding گزارش کنید.
- داده‌ها را به مجموعه آموزش و آزمون با نسبت ۸۰/۲۰ تقسیم کنید.
- ویژگی‌ها را با استفاده از StandardScaler مقیاس بندی کنید.
- توضیح دهید چرا مقیاس بندی ویژگی‌ها برای آموزش شبکه‌های عصبی اهمیت دارد.

(پ) مدل پایه

- یک مدل Linear Regression روی داده‌های آموزش آموزش دهید.
- مقدار RMSE مدل را روی داده‌های آزمون گزارش کنید.
- این مقدار را به عنوان Baseline در نظر بگیرید.

(ت) طراحی مدل MLP

یک مدل MLP با ساختار زیر طراحی کنید:

- لایه ورودی با تعداد ویژگی‌های داده
- دو لایه پنهان با ۶۴ و ۳۲ نرون
- لایه خروجی با یک نرون
- در لایه‌های پنهان از تابع فعال سازی ReLU استفاده کنید.
- تعداد پارامترهای قابل یادگیری شبکه را محاسبه کنید.
- توضیح دهید چرا در مسائل رگرسیون از MSE استفاده می‌شود.

(ث) آموزش مدل

- مدل را با استفاده از بهینه‌ساز Adam برای Epoch ۵۰ آموزش دهید.
- در هر مرحله مقدار Training Loss و Validation Loss را ذخیره کنید.
- نمودار تغییرات این دو مقدار را رسم کرده و روند یادگیری مدل را تحلیل کنید.
- مقدار RMSE مدل MLP روی داده‌های آزمون را گزارش کرده و با مدل خطی مقایسه کنید.

(ج) بررسی ابرپارامترها

تأثیر موارد زیر را بر عملکرد مدل بررسی کنید.

توابع فعال‌سازی

مدل را با سه تابع فعال‌سازی مختلف آموزش دهید:

ReLU •

Tanh •

Sigmoid •

مقدار Validation RMSE هر حالت را گزارش کرده و نتایج را مقایسه کنید.

نرخ یادگیری

مدل را با نرخ‌های یادگیری زیر آموزش دهید:

0.01 •

0.001 •

0.0001 •

تأثیر آن‌ها بر سرعت همگرایی مدل را توضیح دهید.

معماری شبکه

دو معماری زیر را با مدل اولیه مقایسه کنید:

• یک لایه پنهان: (۶۴)

• سه لایه پنهان: (۱۲۸، ۶۴، ۳۲)

مقدار Validation RMSE هر مدل را گزارش کرده و نتایج را تحلیل کنید.

(چ) تحلیل خطای مدل

- پنج نمونه از داده‌های آزمون که بیشترین خطای پیش‌بینی را دارند پیدا کنید.
- قیمت واقعی و قیمت پیش‌بینی‌شده این نمونه‌ها را گزارش کنید.
- توضیح دهید چه ویژگی‌هایی ممکن است باعث خطای زیاد مدل شده باشند.

۶. طبقه‌بندی تصاویر (۳۰ نمره)

در این سؤال قصد داریم از یک شبکه عصبی چندلایه (MLP) برای حل یک مسئله طبقه‌بندی چندکلاسه استفاده کنیم.

مجموعه داده مورد استفاده MNIST است. این مجموعه داده شامل تصاویر سیاه و سفید از ارقام دست‌نویس (۰ تا ۹) می‌باشد و یکی از مجموعه داده‌های کلاسیک در یادگیری ماشین محسوب می‌شود. هدف در این مسئله تشخیص رقم موجود در هر تصویر است.

هر تصویر دارای ابعاد 28×28 پیکسل بوده و به صورت تک‌کاناله (Grayscale) ذخیره شده است. بنابراین هر تصویر را می‌توان به یک بردار 784 بعدی تبدیل (Flatten) کرد.

این مجموعه داده شامل 60000 تصویر برای آموزش و 10000 تصویر برای آزمون است.

بنابراین این مسئله یک مسئله Multi-class Classification با 10 کلاس است.

(الف) بارگذاری و آماده‌سازی داده‌ها

- مجموعه داده MNIST را بارگذاری کنید.
- ابعاد داده‌های آموزش و آزمون را گزارش کنید.
- چند تصویر نمونه از داده‌ها را نمایش دهید.
- تصاویر را به بردارهای 784 بعدی تبدیل (Flatten) کنید.
- مقادیر پیکسل‌ها را به بازه $[0, 1]$ نرمال‌سازی کنید.

(ب) طراحی شبکه عصبی برای طبقه‌بندی

یک شبکه عصبی چندلایه با ساختار زیر طراحی کنید:

- لایه ورودی با 784 نرون
- یک لایه پنهان با 128 نرون
- یک لایه پنهان با 64 نرون
- لایه خروجی با 10 نرون

به سؤالات زیر پاسخ دهید:

- تابع Softmax را تعریف کنید و فرمول ریاضی آن را بنویسید.
- توضیح دهید خروجی Softmax چه تفسیری دارد.
- چرا در مسائل طبقه‌بندی چندکلاسه معمولاً از تابع زیان Cross-Entropy استفاده می‌شود؟
- تفاوت استفاده از MSE و Cross-Entropy در مسائل طبقه‌بندی چیست؟
- تعداد کل پارامترهای قابل یادگیری این شبکه را محاسبه کنید.

(پ) آموزش مدل

- مدل را با استفاده از بهینه‌ساز Adam آموزش دهید.
- در پایان هر Epoch مقدار Training Loss و Training Accuracy را ذخیره کنید.
- نمودار تغییرات Loss و Accuracy را رسم کنید.

(ت) ارزیابی مدل

- دقت (Accuracy) مدل را روی داده‌های آزمون گزارش کنید.
- ماتریس درهم‌ریختگی (Confusion Matrix) را محاسبه و رسم کنید.
- مشخص کنید کدام ارقام بیشترین خطا را دارند و دلیل احتمالی آن را توضیح دهید.

(ث) بررسی مقداردهی اولیه وزن‌ها

- در این بخش تأثیر روش مقداردهی اولیه وزن‌ها را بررسی کنید.
- مدل را یک‌بار با مقداردهی اولیه تصادفی ساده آموزش دهید.
 - مدل را بار دیگر با مقداردهی اولیه Xavier (Glorot) آموزش دهید.
 - نتایج همگرایی و مقدار نهایی Accuracy را مقایسه کنید.
 - توضیح دهید چرا مقداردهی اولیه مناسب برای جلوگیری از مشکل Vanishing/Exploding Gradient اهمیت دارد.

(ج) بررسی اندازه Batch

- مدل را با اندازه‌های مختلف Batch آموزش دهید (برای مثال ۳۲، ۱۲۸ و ۵۱۲).
- نمودار تغییرات Training Loss را برای هر حالت رسم کنید.
- توضیح دهید اندازه Batch چگونه بر نوسان گرادیان و سرعت همگرایی تأثیر می‌گذارد.

(چ) افزایش عمق شبکه

- یک مدل عمیق‌تر با سه لایه پنهان طراحی کنید (برای مثال ۲۵۶، ۱۲۸، ۶۴).
- عملکرد این مدل را با مدل قبلی مقایسه کنید.
- توضیح دهید آیا افزایش عمق همیشه باعث بهبود عملکرد می‌شود یا خیر.

(ح) محدودیت‌های MLP در پردازش تصویر

در پایان به سؤالات زیر پاسخ دهید:

- چرا در این سؤال تصاویر را Flatten کردیم؟
- با این کار چه نوع اطلاعاتی از تصویر از بین می‌رود؟
- چرا برای بسیاری از مسائل بینایی ماشین از شبکه‌های کانولوشنی (CNN) استفاده می‌شود؟